

Formularium - Lean Six Sigma Black Belt

Module 3 - Statistiek, SPC, MSA & Big Data/ML

UGAIN Black Belt - examenformularium

Contents

Les 1 - Intro & Big Data (20/05)	1
Inleiding tot Machine Learning (Naert - Lecture 2, 29/05)	5
Les 2 - Hypothesetoetsen, betrouwbaarheidsintervallen & acceptance sampling (29/05)	7
Les 3 - Regressie & DOE (05/06)	11
Les 4 - SPC & proces-capabiliteit (12/06)	15
Les 5 - MSA / Gage R&R & simulatie (19/06)	17
Root - Voorbeeldexamen: formules per vraag	21
Volledig Excel-formularium	22

Les 1 - Intro & Big Data (20/05)

Bestanden: van *volsem.pdf* (intro/DMAIC), *naert_big_data.pdf* (data & big data). De procesmatige kern + de data-/statistiekbasis hieronder.

Procesmodel (transferfunctie)

$$Y = f(X_1, X_2, \dots, X_n)$$

De output Y is een functie van de proces-inputs (de "X-en"). DMAIC trechtert: Define >100 X-en -> Measure ≤ 20 -> Analyze ≤ 6 -> Improve ≤ 4 -> Control ≤ 3 ("vital few").

Little's Law (flow / doorlooptijd)

$$\text{WIP} = \text{Throughput} \times \text{Doorlooptijd} \iff L = \lambda \cdot W$$

Symbool	Betekenis
L (WIP)	aantal flow units in het systeem (onderhanden werk)
λ	doorvoersnelheid (throughput rate, eenheden per tijd)
W	doorlooptijd (throughput time)

$$\Rightarrow W = \frac{L}{\lambda} = \frac{\text{WIP}}{\text{Throughput}}$$

- **Cyclustijd** = gemiddelde tijd tussen twee opeenvolgende voltooide eenheden.
- **Bottleneck** = processtap met de langste cyclustijd; bepaalt de doorvoer.

Flow efficiency

$$\text{Flow efficiency} = \frac{\text{waarde-toevoegende tijd}}{\text{totale doorlooptijd}}$$

Typisch is ~95% van de doorlooptijd niet-waarde-toevoegend.

Basis beschrijvende statistiek

(Fundament voor alle volgende lessen; in de intro al via μ en σ .)

Maat	Steekproef (sample)	Populatie
Gemiddelde	$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$	μ
Variantie	$s^2 = \frac{1}{n-1} \sum (x_i - \bar{x})^2$	$\sigma^2 = \frac{1}{N} \sum (x_i - \mu)^2$
Standaardafwijking	$s = \sqrt{s^2}$	$\sigma = \sqrt{\sigma^2}$
Bereik (range)	$R = x_{\max} - x_{\min}$	

Let op de noemer $n - 1$ (vrijheidsgraden) bij de steekproef-variantie versus N bij de populatie.

Meetschalen (Stevens) - “NOIR”

Schaal	Kenmerk	Toegelaten	Centrummaat	Voorbeeld (productie)
Nominaal	categorieën, geen ordening	$=, \neq$	modus	type defect (barst/kras/verkleuring), machine-ID, productlijn
Ordinaal	geordende categorieën, afstand niet betekenisvol	$<, >$	mediaan	kwaliteitsscore (slecht < matig < goed), hardheidsklasse, Likert-schaal
Interval	gelijke afstanden, willekeurig nulpunt	$+, -$	gemiddelde	temperatuur in °C, kalenderdatum (20°C is niet “2x warmer” dan 10°C)
Ratio	gelijke afstanden + absoluut nulpunt	$+, -, \times, \div$	(geom.) gemiddelde	lengte, gewicht, doorlooptijd, aantal defecten, concentratie

Hoger op de ladder = meer informatie. Het meetniveau bepaalt welke statistiek/test zinvol is (bv. een gemiddelde berekenen heeft geen zin voor nominale data; verhoudingen enkel bij ratio).

Kansverdelingen: pdf/cdf, sampling & inference

$$f(x) = P(X = x) \text{ (pdf, vorm),} \quad F(x) = P(X \leq x) = \int_{-\infty}^x f(t) dt \text{ (cdf, gecumuleerd)}$$

Naast de normale verdeling zijn er nog enkele kernverdelingen. De vraag die alles sorteert: **tel** je iets (discreet, staafjes) of **meet** je iets op een continue schaal (continu, curves)?

Verdeling	Type	pmf / pdf	Param.	$E[X]$; $Var[X]$	Voorbeeld
Bernoulli	discreet	$P(1) = p, P(0) = 1 - p$	p	$p ; p(1 - p)$	1 ja/nee-trial: muntworp; 1 stuk OK/NOK

Verdeling	Type	pmf / pdf	Param.	$E[X]$; $Var[X]$	Voorbeeld
Binomiaal	discreet	$\binom{n}{k} p^k (1-p)^{n-k}$	n, p	np ; $np(1-p)$	successen in n vaste trials: defecten in batch van 100
Poisson	discreet	$\frac{\lambda^k e^{-\lambda}}{k!}$	λ	λ ; λ	zeldzame events per interval: pannes per week, aankomsten per uur
Uniform	continu	$\frac{1}{b-a}$ op $[a, b]$	a, b	$\frac{a+b}{2}$; $\frac{(b-a)^2}{12}$	enkel het bereik gekend: random getal 0-1; afrondingsfout
Exponentieel	continu	$\lambda e^{-\lambda x}, x \geq 0$	λ	$\frac{1}{\lambda}$; $\frac{1}{\lambda^2}$	wachttijd tot volgend event: tijd tot volgende panne (geheugenloos)
Normaal	continu	$\frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}(\frac{x-\mu}{\sigma})^2}$	μ, σ	μ ; σ^2	som/gemiddelde van veel kleine effecten (CLT): diameter, vulgewicht

Hoe kiezen, in één adem: tel je of meet je? *Tellen:* één trial (Bernoulli), een vaste batch (Binomiaal) of open-einde zeldzame events (Poisson)? *Metten:* vlak over een bereik (Uniform), een wachttijd (Exponentieel) of een gecentreerde bel (Normaal)? Discriminator tellen: Binomiaal heeft een noemer ("12 op 100"), Poisson niet ("12 events deze week"). Poisson-vingerafdruk: gemiddelde $\approx$ variantie ($= \lambda$).

Verbanden (één familie): stapel n Bernoulli-trials $\rightarrow$ **Binomiaal**; Binomiaal met grote n en kleine $p \rightarrow$ **Poisson**; Binomiaal/sommen met grote $n \rightarrow$ **Normaal** (CLT). **Poisson** telt de events, **Exponentieel** meet de tussentijden (zelfde λ , vandaar geheugenloos: modelleert toevallige uitval, niet slijtage - dat is Weibull). (De Naert-deck vermeldt ook de **beta-verdeling** voor afkeurfracties op $[0, 1]$.)

Sampling vs. inference - twee zijden van dezelfde medaille: - **Sampling:** van verdeling $\rightarrow$ data ("doet de natuur"). - **Inference:** van data $\rightarrow$ verdeling ("doet de statistiek").

De kansverdeling en de (oneindige) zee aan data zijn wiskundig één en hetzelfde. Inference laat ook **voorspelling** toe (bv. uit $\lambda = 2,96$ klanten/min volgt: $< 2\%$ kans op > 7 klanten/min).

Marginale & voorwaardelijke kans, onafhankelijkheid

Bij twee variabelen heb je de **gezamenlijke (joint) verdeling** $P(X, Y)$. *Associatie* = de joint bevat informatie die je **niet** kan achterhalen door X en Y apart te bestuderen.

Begrip	Formule	Intuïtie
Marginaal	$P(X) = \int_y P(X, Y) dy$ (of $\sum_y$)	“kolommen wegfilteren”
Voorwaardelijk	$P(Y X) = \frac{P(X, Y)}{P(X)}$	“rijen filteren waar $X \approx x$ ”
Bayes	$P(X Y) = \frac{P(Y X) P(X)}{P(Y)}$	conditie omkeren

Onafhankelijkheid - drie equivalente uitdrukkingen:

$$P(X, Y) = P(X) P(Y) \iff P(Y | X) = P(Y) \iff P(X | Y) = P(X)$$

Kennis van X geeft dan géén extra informatie over Y . *Nagaan of onafhankelijk*: vergelijk $P(Y | X)$ met $P(Y)$ - verschillen ze, dan zijn de variabelen afhankelijk.

Voorbeeld (productiekwaliteit - contingentietabel). 500 producten van 2 lijnen, ingedeeld naar kwaliteit K :

	Accepted	Downgraded	Rejected	Totaal
Lijn 1	200	50	20	270
Lijn 2	150	40	40	230
Totaal	350	90	60	500

- *Joint*: $P(\text{Lijn 2, Acc}) = \frac{150}{500} = 0,30$.
- *Marginaal* $P(K)$: $P(\text{Acc}) = \frac{350}{500} = 0,70$, $P(\text{Down}) = 0,18$, $P(\text{Rej}) = 0,12$.
- *Voorwaardelijk* $P(K | \text{Lijn 1})$ (rij Lijn 1 delen door 270): $P(\text{Acc} | \text{L1}) = \frac{200}{270} \approx 0,74$, $P(\text{Rej} | \text{L1}) \approx 0,07$.
- *Onafhankelijk?* $P(\text{Acc} | \text{L1}) \approx 0,74 \neq P(\text{Acc}) = 0,70 \rightarrow$ **niet onafhankelijk**: Lijn 1 levert verhoudingsgewijs meer Accepted (74% vs 70%) en minder Rejected (7% vs 12%); lijn en kwaliteit hangen samen.

Voorwaardelijke verwachtingswaarde $E[Y | X]$

$$E[Y | X = x] = \int_y y \cdot P(Y = y | X = x) dy$$

Dit is een functie van x alleen: de **regressielijn**. Te onthouden: vrijwel alle *supervised machine learning* (van lineaire regressie tot diepe neurale netwerken) is in essentie een schatting van $E[Y | X]$.

Associatie vs. interventie (causaliteit)

Twee fundamenteel verschillende vragen:

$$\underbrace{P(Y | X = x)}_{\text{associatie: we *observeren*}} \neq \underbrace{P(Y | \text{do}(X = x))}_{\text{interventie: we *forceren*}}$$

In het algemeen zijn deze **niet** gelijk. Uit observationele data alleen kan je het effect van een interventie *niet* bepalen - je hebt steeds bijkomende **causale aannames** nodig.

- **PINO-principe**: *Prediction Is Not Optimization*; de *cum hoc ergo propter hoc*-drogreden = correlatie verwarren met causaliteit.
- **Confounder**: verborgen factor Z die zowel X als Y drijft (bv. ijsverkoop $\leftrightarrow$ reddingsacties, beide gedreven door warm weer). Wie de confounder negeert, ziet soms het *omgekeerde teken* (**Simpson's paradox**: een medicijn lijkt globaal te schaden maar helpt in elke subgroep).

- **Causaal diagram (DAG)** = Directed Acyclic Graph: knopen = variabelen, pijlen = veronderstelde causale relaties, geen cykels. Een DAG is een *aanname* over het fysisch proces achter de data.
- **Wat doet een interventie?** $\text{do}(X = x)$ forceert X op een waarde en **verwijdert alle inkomende pijlen** naar X (sluit de “achterdeur”). Bv. koper legeren in staal: $\text{do}(\text{Cu})$ sluit het achterdeurpad via schroot.
- Eenzelfde datapatroon kan uit verschillende structuren komen: *direct* ($X \rightarrow Y$), *mediator* ($X \rightarrow M \rightarrow Y$), *omgekeerd* ($Y \rightarrow X$) of *confounder* ($X \leftarrow Z \rightarrow Y$).

Randomisatie: RCT & A/B-testen

- Een **Randomized Controlled Trial (RCT)** wijst eenheden willekeurig toe aan interventie-/controlegroep. Randomisatie **breekt alle achterdeurpaden** - ook via confounders die we niet eens gemeten hebben. Daarom geldt in een RCT: $P(Y \mid \text{do}(T = t)) = P(Y \mid T = t)$.
- **A/B-testen** (bv. webshop toont nieuwe pagina aan 50% van de bezoekers) zijn de digitale RCT: het gemeten verschil is een *causale* schatting. Dit is exact de do-operatie die **DOE** (Les 3) via randomisatie/blocking realiseert.
- Wanneer randomiseren niet kan (ethisch/praktisch/financieel): do-calculus (Pearl), matching/propensity scores, instrumentele variabelen, difference-in-differences, regression discontinuity, SEM.

Studiewijzer-checklist (Naert - Lecture 1: big data)

Kanstheorie & statistiek: sampling vs. inference ✓ · marginale kans ✓ · voorwaardelijke kans ✓ · onafhankelijkheid kennen ✓ · onafhankelijkheid nagaan ✓ · voorwaardelijke verwachtingswaarde ✓
Causaliteit & interventie: cum hoc / PINO ✓ · causaal diagram ✓ · eenvoudige causale redenering ✓ · RCT & A/B-testen als gouden standaard ✓

Inleiding tot Machine Learning (Naert - Lecture 2, 29/05)

Tweede big-data lecture (Karsten Naert). Hieronder de uitgewerkte studiewijzer.

Terminologie: AI / ML / Supervised / Unsupervised

AI $\supset$ ML $\supset$ DL (deep learning) - “geen magie, gewoon statistiek”. Drie leerparadigma’s: - **Supervised**: leert uit gelabelde data (x_i, y_i) , modelleert $P(Y \mid X)$ (bv. treksterkte voorspellen uit procesparameters). Twee types: **regressie** (continue y) en **classificatie** (categorische y). - **Unsupervised**: enkel inputs x_i , modelleert $P(X)$ - ontdekt structuur (clustering, anomaliedetectie). - **Reinforcement**: een agent leert via beloningen, modelleert $P(Y \mid \text{do}(X))$ (link met interventie uit Lecture 1).

Loss-functies (rol + MSE/MAE)

Een **loss-/kostfunctie** kwantificeert hoe slecht een model presteert: $L_D(\hat{f}) = \frac{1}{N} \sum_{i=1}^N \ell(y_i, \hat{f}(x_i))$.

Trainen = de gewichten kiezen die de loss minimaliseren: $\hat{\theta}_D = \arg \min_{\theta} L_D(\hat{f}_{\theta})$. - **MSE** = $\frac{1}{N} \sum (y_i - \hat{f}(x_i))^2$: kwadratisch, straft grote afwijkingen hard, **gevoelig voor uitschieters**, impliceert Gaussische fouten. - **MAE** = $\frac{1}{N} \sum |y_i - \hat{f}(x_i)|$: lineair, **robuuster** bij uitschieters, impliceert Laplacianse fouten. - **Huber** combineert MSE (kleine fouten) + MAE (grote fouten); voor classificatie: **cross-entropie**. De keuze van de loss is een *modelleringskeuze* (bepaalt wat geoptimaliseerd wordt en de impliciete foutenverdeling).

Cross-validatie & train-test-split

Een complexer model doet het op de trainingsdata altijd minstens even goed; wat telt is de prestatie op **ongeziene** data. Daarom: train op de **trainset**, evalueer op een **testset** die het model nooit zag. Wie hyperparameters herhaaldelijk op dezelfde testset tunet, overtraint ook dáárop -> gebruik een derde **validatieset**. **k-voudige cross-validatie**: verdeel de data in k delen, train telkens op

$k - 1$ delen en valideer op het overige, en middel de prestatie. (Onthoud: *parameters* worden door het algoritme gevonden, *hyperparameters* - polynoomgraad, boomdiepte, λ - kiest de analist.)

Bias-variance trade-off

De verwachte fout ontbindt in drie bronnen:

$$E[(y - \hat{f}(x))^2] = \underbrace{\text{Bias}^2}_{\text{systematisch}} + \underbrace{\text{Var}}_{\text{gevoeligheid}} + \underbrace{\sigma^2}_{\text{ruis}}$$

- **Bias:** de modelklasse kan $f(x)$ niet vatten -> **underfitting** (te simpel). - **Variance:** het model is te gevoelig voor de toevallige trainingsdata -> **overfitting** (te complex). - σ^2 : inherente ruis - niet te reduceren. Stijgt de complexiteit, dan daalt bias maar stijgt variance: de totale fout volgt een **U-vorm**, met het optimum ertussenin. (SPC-analogie: hoge bias/lage variance = consistent maar systematisch fout; lage bias/hoge variance = gemiddeld juist maar onbetrouwbaar.)

Confusion matrix & evaluatie van classificatie

Bij classificatie is er niet één foutgetal maar verschillende soorten fouten. De 2×2 -matrix telt werkelijk vs. voorspeld:

	Voorspeld +	Voorspeld -
Werkelijk +	TP	FN
Werkelijk -	FP	TN

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}, \quad \text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}, \quad F_1 = \frac{2PR}{P + R}$$

- *Accuracy* is misleidend bij klasse-onevenwicht. *Precision* = "hoe vaak klopt een positief?"; *Recall* = "hoeveel echte positieven vinden we?"; F_1 = harmonisch gemiddelde. - **Welke metric?** Domeinbeslissing: vals alarm duur (alarmsysteem) -> optimaliseer **precision**; gemist defect duur (veiligheidskritisch) -> optimaliseer **recall**.

Neurale netwerken (hidden layers & deep learning)

Eén neuron: $y = f(w_1x_1 + \dots + w_nx_n + b)$ met gewichten w_i , bias b en niet-lineaire **activatie** f (ReLU, sigmoid, tanh). **Deep learning** = meerdere **verborgen (hidden) lagen** stapelen. Leren via **backpropagation** (gradiënt) + gewichten bijstellen richting lagere loss. *Universele approximatiestelling*: met genoeg neuronen kan elke continue functie benaderd worden. Risico: met miljoenen parameters leert het netwerk de ruis mee (overfitting) -> **regularisatie** (dropout, early stopping, weight decay). Schitteren bij grote datasets / sterk niet-lineair / ongestructureerde input (beeld, tekst); minder bij kleine datasets of vereiste interpreteerbaarheid. Architecturen: MLP (tabeldata), CNN (beeld), RNN/LSTM (tijdreeksen), Transformer (taal/LLMs), autoencoder (anomalie).

Beslissingsbomen (werkingsprincipe)

Splits de invoerruimte successievelijk op **drempelwaarden** - een reeks ja/nee-vragen die de data in steeds homogenere groepen verdelen. Voordelen: makkelijk te visualiseren, minimale data-voorbereiding, gaan om met ontbrekende waarden. Nadelen: gevoelig voor overfitting, meestal geen fysische/causale interpretatie. **Ensembles** lossen dit op: **Random Forest** (veel bomen op willekeurige subsets, dan middelen -> robuust) en **Gradient Boosting** (XGBoost/LightGBM: elke nieuwe boom corrigeert de vorige -> state-of-the-art voor tabeldata).

Bayesiaanse methoden (voordelen voor gestructureerde data)

Andere filosofie dan de frequentistische: hier zijn **parameters zelf stochastisch**. Kern = de regel van Bayes:

$$P(\theta \mid \text{data}) = \frac{\overbrace{P(\text{data} \mid \theta)}^{\text{likelihood}} \cdot \overbrace{P(\theta)}^{\text{prior}}}{P(\text{data})} \quad (= \text{posterior})$$

met **prior** $P(\theta)$ (voorkennis), **likelihood** $P(\text{data} \mid \theta)$ (datamodel) en **posterior** $P(\theta \mid \text{data})$ (bijgewerkte kennis). **Voordelen** (vooral bij gestructureerde, domeinrijke problemen): nuttig bij **weinig observaties**, als er **rijke domeinkennis** is, als de **structuur** bekend is, en wanneer je **onzekerheid** mee wil terugkrijgen (niet enkel een puntschatting). Bv. staalfabriek: a priori weten dat vloeibaar staal tussen 1400-1800 °C ligt. In de praktijk: MCMC (PyMC, Stan).

Studiewijzer-checklist (Naert - Lecture 2: ML)

Kernbegrippen: terminologie AI/ML/supervised/unsupervised ✓ · rol van loss-functies + MSE/MAE ✓ · cross-validatie & train-test-split ✓ · bias-variance trade-off ✓ · confusion matrix & evaluatie ✓
Methoden: neurale netwerken (hidden layers, deep learning) ✓ · beslissingsbomen ✓ · Bayesiaanse methoden ✓

Les 2 - Hypothesetoetsen, betrouwbaarheidsintervallen & acceptance sampling (29/05)

Bestanden: Ottovoy Testing of Hypotheses, Confidence Intervals, Acceptance Sampling. Dit is de meest formulerijke les.

A. Beslissingskader

	Werkelijkheid: H_0 waar	Werkelijkheid: H_A waar
Beslissing: H_0	OK	Type-II fout, risico β
Beslissing: H_A	Type-I fout, risico α	OK

- H_0 = status quo (do-nothing); H_A = special action. H_0 moet altijd de status quo uitdrukken; α moet klein zijn.
- α = **significantie** = $P[\text{ten onrechte } H_0 \text{ verwerpen}]$ = **producer's risk** (bij acceptance sampling).
- β = $P[\text{ten onrechte } H_0 \text{ aanvaarden}]$ = **consumer's risk**.
- **p-waarde** = kans op een waarde die minstens evenveel afwijkt als de waarneming, *gegeven dat H_0 waar is*. Beslisregel: **verwerp H_0 als p-waarde** < α (equivalent met teststatistiek vs. kritieke waarde).
- α vooraf vastleggen (ontwerpparameter), nooit na het zien van de teststatistiek.

B. Toetsprocedure (recept, 7 stappen)

1. Formuleer H_0 en H_A (één- of tweezijdig).
2. Kies significantie α .
3. Kies teststatistiek + steekproevenverdeling.
4. Bepaal steekproefgrootte n (rekening houdend met α en β).
5. Bepaal referentieverdeling + kritieke waarde (onder H_0).
6. Trek steekproef, bereken teststatistiek.
7. Vergelijk met kritieke waarde -> conclusie.

Voorbeeld (de 7 stappen toegepast - t-toets voor het gemiddelde). Een proces maakt onderdelen met een kritische maat, normaal verdeeld rond 10. Na vervanging van een machineonderdeel vreest het management dat de stukken kleiner zijn geworden. 20 stukken worden gemeten: $\bar{x} = 9,928$, $s = 0,109$. 1. $H_0 : \mu = 10$ (proces nog gecentreerd) vs. $H_A : \mu < 10$ (vershoven naar beneden) -

eenzijdig. 2. $\alpha = 2\%$ (conservatief: enkel bijsturen bij sterk bewijs). 3. Teststatistiek $t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$; steekproevenverdeling $t(n-1) = t(19)$. 4. $n = 20$ (gegeven). 5. Kritieke waarde (eenzijdig links): $t_{0,02;19} = -2,20$ via =T.INV(0,02;19). 6. $t = \frac{9,928 - 10}{0,109/\sqrt{20}} = -2,95$. 7. $-2,95 < -2,20$ (en p-waarde $= 0,4\% < \alpha$, via =T.DIST(-2,95;19;WAAR)) -> **verwerp** H_0 : het proces is significant naar beneden verschoven en moet bijgesteld worden.

C. Kern-teststatistieken

Standaardisatie (Z): als $X \sim N(\mu, \sigma)$ dan

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$$

t-toets voor het gemiddelde (df = $n - 1$):

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} \quad \text{referentie: } t(n-1)$$

Gebruik: testen of het procesgemiddelde verschoven is. ($t(n) \rightarrow Z$ als $n \rightarrow \infty$.)

χ^2 -toets voor de variantie / standaardafwijking (df = $n - 1$):

$$\chi^2 = \frac{(n-1)s^2}{\sigma_0^2} \quad \text{referentie: } \chi^2(n-1)$$

Gebruik: testen of de procesvariabiliteit veranderd is. (χ^2 is asymmetrisch, enkel positief; $\chi^2(n) \rightarrow N(n, 2n)$.)

F-toets voor twee varianties (vergelijk de spreiding van 2 normale populaties; df = $n_1 - 1$ teller, $n_2 - 1$ noemer):

$$F = \frac{s_1^2}{s_2^2} \quad \text{en pivot} \quad \frac{s_1^2}{s_2^2} \cdot \frac{\sigma_2^2}{\sigma_1^2} \sim F(n_1 - 1, n_2 - 1)$$

Gebruik: testen of de ene machine/proces *nauwkeuriger* werkt dan de andere ("nauwkeuriger" $\Leftrightarrow$ kleinere σ^2). Excel: kritieke waarde =F.INV(α ;df1;df2) (linkerstaart) of =F.INV.RT(α ;df1;df2) (rechterstaart); p-waarde ineens met =F.TEST(reeks1; reeks2).

D. Betrouwbaarheidsintervallen (CI)

Centrale limietstelling (CLT): voor voldoende grote n is het steekproefgemiddelde

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right), \quad \text{standaardfout } SE = \frac{\sigma}{\sqrt{n}} \approx \frac{s}{\sqrt{n}}$$

CI voor het gemiddelde μ (tweezijdig, $(1 - \alpha) \cdot 100\%$):

$$\bar{x} - t_{n-1; 1-\alpha/2} \frac{s}{\sqrt{n}} \leq \mu \leq \bar{x} + t_{n-1; 1-\alpha/2} \frac{s}{\sqrt{n}}$$

Eénzijdig (bovengrens): $\mu \in \left] -\infty, \bar{x} + t_{n-1; 1-\alpha} \frac{s}{\sqrt{n}} \right]$.

CI voor de variantie σ^2 (via χ^2):

$$\frac{(n-1)s^2}{\chi_{n-1; 1-\alpha/2}^2} \leq \sigma^2 \leq \frac{(n-1)s^2}{\chi_{n-1; \alpha/2}^2}$$

Eénzijdige ondergrens voor σ : $\sigma \geq \sqrt{\frac{(n-1)s^2}{\chi_{n-1; 1-\alpha}^2}}$.

CI voor de verhouding van twee varianties σ_2^2/σ_1^2 (via F; examen vraag 2). Eénzijdige $(1-\alpha)$ -ondergrens:

$$\frac{\sigma_2^2}{\sigma_1^2} \geq \frac{s_2^2}{s_1^2} \cdot F_\alpha(n_1-1, n_2-1), \quad F_\alpha = F.INV(\alpha; n_1-1; n_2-1)$$

Beslisregel: ligt de hele ondergrens $L > 1$, dan is $\sigma_2^2 > \sigma_1^2$ aangetoond (machine 1 nauwkeuriger).
Voorbeeld: $n_1=10, n_2=15 \Rightarrow F_{0,05}(9; 14) = 0,3305$; met $s_1^2=0,004, s_2^2=0,015$: $L = \frac{0,015}{0,004} \cdot 0,3305 = 1,24 > 1 \rightarrow$ vermoeden bevestigd. (Tweezijdig: deel ook door $F_{1-\alpha/2}$ voor de bovengrens.)

CI voor een fractie/proportie π (grote steekproef, normale benadering):

$$\pi = p \pm Z_{1-\alpha/2} \sqrt{\frac{p(1-p)}{n}}, \quad Z_{0.975} = 1.96$$

Geldig als minstens ~ 5 defecten in de steekproef.

Steekproefgrootte (gewenste halve breedte/marge E):

$$\text{gemiddelde: } n = \left(\frac{Z_{1-\alpha/2} \sigma}{E} \right)^2 \quad \text{proportie: } n = \frac{Z_{1-\alpha/2}^2 p(1-p)}{E^2}$$

Worst case proportie bij $p = 0.5$. Vuistregel: accuraatheid verdubbelen (CI-breedte halveren) = steekproef $\times 4$.

Equivalentie CI $\leftrightarrow$ toets: toetsen met een $(1-\alpha) \cdot 100\%$ -CI heeft significantie α . Als $\pi_0 \in \text{CI}$ $\rightarrow$ aanvaard H_0 , anders verwerp. Betrouwbaarheidsniveau en significantie bevatten dezelfde info.

E. Acceptance sampling

Basis: lotfractie defecten $\pi = D/N$; schatting uit steekproef $p = d/n$. P is zuiver (unbiased): $E[P] = \pi$.

Steekproevenverdeling: correct = hypergeometrisch, goed benaderd door **binomiaal** (tenzij kleine populatie):

$$P[d = i] = \binom{n}{i} \pi^i (1-\pi)^{n-i}, \quad \sigma_P = \sqrt{\frac{\pi(1-\pi)}{n}}$$

(σ_P^2 daalt lineair met n ; verdeling wordt normaal door CLT.)

Plannen voor attributen: - Enkelvoudig (n, c) : aanvaard als $d \leq c$. - Dubbel $(n_1, c_1, c_2) + (n_2, c_3)$. - Sequentieel (Ac, Re) (Wald-Wolfowitz) - efficiëntst. - **OC-curve** = $P[\text{aanvaarden}]$ als functie van π . Equivalente plannen = zelfde OC-curve. - AQL = acceptable quality level (goede kwaliteit); $LQL/LTPD$ = limiting quality level (slechte kwaliteit). Normen: ISO 2859 (attributen), ISO 3951 (variabelen).

Plan voor variabelen (n, k) bij ondergrens-spec ξ :

$$Q = \frac{\bar{x} - \xi}{s}, \quad \text{aanvaard als } Q \geq k \quad (k \approx t(1-\alpha, p_0, n))$$

(k is de tegenhanger van c .) Variabelen-plannen zijn efficiënter dan attribuut-plannen.

Stratificatie (variantiereductie). *Idee:* splits de populatie in homogenere deelgroepen (strata) en bemonster elk apart; zo verwijder je de spreiding *tussen* de strata uit de schattingsfout. De gestratificeerde schatter combineert de deel-schattingen met hun gewicht W_h (= aandeel van stratum h):

$$P_s = \sum_h W_h P_h \quad (2 \text{ strata: } W_A P_A + W_B P_B), \quad E[P_s] = \pi \text{ (zuiver)}$$

Populatie-decompositie: $\sigma^2 = \underbrace{\sum_h W_h \sigma_h^2}_{\text{within}} + \underbrace{\sum_h W_h (\mu_h - \mu)^2}_{\text{between}}$, met $\mu = \sum_h W_h \mu_h$. - **Proportionele** allocatie ($n_h = nW_h$): $\sigma^2[P_s] = \frac{1}{n} \sum_h W_h \sigma_h^2$ (enkel de *within*-term blijft over). Vergelijk met SRS: $\sigma^2[P] = \frac{\pi(1-\pi)}{n} = \frac{\sigma^2}{n}$ (within + between). De winst = de weggevalle *between*-variantie.

- **Optimale (Neyman)** allocatie: $n_A = n \cdot \frac{W_A \sigma_A}{W_A \sigma_A + W_B \sigma_B}$ - geef het stratum met de grootste spreiding méér steekproef. Proportioneel is enkel optimaal als $\sigma_A = \sigma_B$.

Voorbeeld. Lot van $N = 10000$ tegels uit 2 batches: A ($N_A = 6000$, $W_A = 0,6$, defectgraad $\pi_A = 3\%$) en B ($N_B = 4000$, $W_B = 0,4$, $\pi_B = 0,5\%$). We trekken $n = 100$. - Lotfractie: $\pi = W_A \pi_A + W_B \pi_B = 0,6 \cdot 0,03 + 0,4 \cdot 0,005 = 2\%$. - Within-varianties: $\sigma_A^2 = \pi_A(1-\pi_A) = 0,0291$, $\sigma_B^2 = 0,004975$. - **Proportioneel** ($n_A = 60$, $n_B = 40$): $\sigma^2[P_s] = \frac{0,6 \cdot 0,0291 + 0,4 \cdot 0,004975}{100} = 0,000195$. - **SRS** (geen stratificatie): $\sigma^2[P] = \frac{0,02 \cdot 0,98}{100} = 0,000196$.

- **Conclusie:** hier is de winst minuscule (0,000195 vs 0,000196) want de *between*-variantie is klein. Voor fractie-defecten loont stratificatie dus zelden de extra organisatie. Bij **variabelen/gemiddelden** met goed gescheiden strata kan de winst wél groot zijn: bv. 2 gelijke strata met $\mu_A = 10$, $\mu_B = 15$ en gemeenschappelijke $\sigma^2 = 4 \rightarrow \sigma^2[\bar{x}]$ daalt van $\frac{4+(5)^2/4}{100} = 0,1025$ (SRS) naar $\frac{4}{100} = 0,04$ (gestratificeerd). - **Optimaal (Neyman):** met $\sigma_A = \sqrt{0,0291} = 0,171 > \sigma_B = 0,071$ wordt $n_A = 100 \cdot \frac{0,6 \cdot 0,171}{0,6 \cdot 0,171 + 0,4 \cdot 0,071} \approx 78$ (i.p.v. 60) - méér steekproef naar het meer variabele stratum A.

Steekproefmethoden & vertekening (bias) - conceptueel, examenvraag 1. - **Methoden:** **SRS** (enkelvoudig random: elk element gelijke kans) · **systematisch** (elke k -de) · **gestratificeerd** (random binnen homogene strata - zie boven) · **cluster** (kies hele groepen/clusters en meet iedereen daarin). - **Vertekening:** **selectiebias** (de steekproef is niet representatief door het selectieproces) en **non-response bias** (gekozen eenheden antwoorden niet en verschillen systematisch van wie wél antwoordt). Belangrijk: non-response treedt op na de selectie, dus **geen enkele** steekproefmethode (ook cluster sampling niet) is er immuun voor.

F. Normaalverdeling (basis; volledige capability-behandeling in Les 4)

$$\varphi(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}, \quad \Phi(x) = \int_{-\infty}^x \varphi(t) dt$$

Excel: CDF = NORM.DIST(x; μ; σ; TRUE), inverse = NORM.INV(p; μ; σ), random = NORM.INV(RAND(); μ; σ). Fractie conform = $\Phi(x_U) - \Phi(x_L)$.

Koppeling spec-breedte <-> capability:

$$X_U - X_L = 6\sigma \Rightarrow 99.73\% \text{ conform (0.27\% defect)}, C_{pk} = 1$$

$$X_U - X_L = 8\sigma \Rightarrow 99.9937\% \text{ conform (63 ppm defect)}, C_{pk} = 1.33$$

$$C_{pk} = \min\left(\frac{X_U - \mu}{3\sigma}, \frac{\mu - X_L}{3\sigma}\right)$$

Lotdefecten bij gekend C_{pk} : $E[i] = N \cdot \pi$ (bv. $C_{pk} = 1 \Rightarrow \pi = 0.27\% \Rightarrow$ in $N = 10000$: $E[i] = 27$).

DPMO, sigma-niveau & de 1,5σ-drift (Motorola). Een proces op " k sigma" betekent dat de dichtstbijzijnde speclimiet op k standaardafwijkingen van het gemiddelde ligt. De defectkans lees je af uit de standaardnormale verdeling via de Z-waarde:

$$\text{DPMO} = P(\text{defect}) \times 10^6 = (1 - \Phi(Z_{\text{eff}})) \times 10^6$$

- **Korte termijn (gecentreerd, geen drift):** $Z_{\text{eff}} = k$. Een perfect gecentreerd 6σ -proces geeft dan $P(Z > 6) \approx 0,002$ DPMO (≈ 2 defecten per miljard).

- **Lange termijn - de 1,5 σ -drift:** Motorola stelde empirisch vast dat een procesgemiddelde over de lange termijn met $\pm 1,5\sigma$ verschuift (slijtage, temperatuur, operator, materiaal, kalibratie). Reken daarom met $1,5\sigma$ minder marge naar de dichtstbijzijnde limiet - de shift gaat naar één kant, dus **eenzijdig**:

$$Z_{\text{eff}} = k - 1,5 \quad \Rightarrow \quad \text{DPMO} = (1 - \Phi(k - 1,5)) \times 10^6$$

Zo wordt een 6 σ -proces in de praktijk een 4,5 σ -marge: $P(Z > 4,5) = 3,4 \times 10^{-6} \Rightarrow$
6 σ = 3,4 DPMO.

Sigma-niveau k (KT)	$Z_{\text{eff}} = k - 1,5$	DPMO (met 1,5 σ -drift)	% Yield
1	-0,5	691.462	30,85%
2	0,5	308.538	69,15%
3	1,5	66.807	93,32%
4	2,5	6.210	99,38%
5	3,5	233	99,977%
6	4,5	3,4	99,99966%

Excel: DPMO uit sigma-niveau = $(1 - \text{NORM.S.DIST}(k - 1,5; \text{WAAR})) * 1000000$; omgekeerd het (KT-)sigma-niveau uit DPMO = $\text{NORM.S.INV}(1 - \text{DPMO}/1000000) + 1,5$. (De *capability-context*, $C_p/C_{pk}/P_p/P_{pk}$, staat volledig in Les 4.)

G. Relevante Excel-functies

(Nederlandse Excel gebruikt puntkomma's als scheidingsteken; WAAR/ONWAAR = TRUE/FALSE.)

Doel	Excel-functie
Gemiddelde / std / variantie (steekproef)	=AVERAGE(...), =STDEV.S(...), =VAR.S(...)
Normale CDF / inverse	=NORM.DIST(x; μ ; σ ; WAAR), =NORM.INV(p; μ ; σ)
Standaardnormaal Z / inverse	=NORM.S.DIST(z; WAAR), =NORM.S.INV(p) -> $Z_{0,975} = \text{NORM.S.INV}(0,975) = 1,96$
t kritieke waarde	eenzijdig =T.INV(α ; df), tweezijdig =T.INV.2T(α ; df)
t p-waarde	links =T.DIST(t; df; WAAR), rechts =T.DIST.RT(t; df), tweezijdig =T.DIST.2T(ABS(t); df)
t-toets ineens (2 reeksen)	=T.TEST(bereik1; bereik2; zijden; type)
χ^2 kritieke waarde / p-waarde	=CHISQ.INV.RT(α ; df); =CHISQ.DIST.RT(χ^2 ; df)
Binomiale kans (acceptance sampling)	=BINOM.DIST(d; n; π ; cumulatief)
Hypergeometrische kans	=HYPGEOM.DIST(d; n; D; N; cumulatief)
Halve breedte CI gemiddelde	=CONFIDENCE.T(α ; s; n) (of =CONFIDENCE.NORM(α ; σ ; n) bij gekende σ)

Les 3 - Regressie & DOE (05/06)

Bestanden: De Vuyst BB_Regression, BB_DOE. Twee blokken: (1) regressie, (2) ANOVA & Design of Experiments.

A. Enkelvoudige lineaire regressie

Model: $Y = \beta_0 + \beta_1 x + \varepsilon$, $\varepsilon \sim N(0, \sigma^2)$ - $\mu_{Y|x} = E[Y|x] = \beta_0 + \beta_1 x$, en $\text{Var}[Y|x] = \sigma^2$ (gelijke spreiding voor alle x = **homoscedasticiteit**).

Kleinste kwadraten (normaalvergelijkingen): minimaliseer $L = \sum_i (Y_i - \beta_0 - \beta_1 x_i)^2$:

$$\hat{\beta}_1 = \frac{S_{xY}}{S_{xx}}, \quad \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{x}$$

met $S_{xx} = \sum_i (x_i - \bar{x})^2$, $S_{xY} = \sum_i (x_i - \bar{x})(Y_i - \bar{Y})$, $S_{YY} = \sum_i (Y_i - \bar{Y})^2$. Gefitte lijn (predictie): $\hat{Y}(x) = \hat{\beta}_0 + \hat{\beta}_1 x$.

ANOVA-ontbinding:

$$SS_T = \sum (Y_i - \bar{Y})^2, \quad SS_E = \sum (Y_i - \hat{Y}_i)^2, \quad SS_R = \sum (\hat{Y}_i - \bar{Y})^2$$

$$\boxed{SS_T = SS_R + SS_E} \quad \text{df: } (n-1) = (1) + (n-2) \text{ [enkelvoudig]}$$

- **Determinatiecoëfficiënt:** $R^2 = \frac{SS_R}{SS_T} = 1 - \frac{SS_E}{SS_T}$ (= fractie verklaarde variabiliteit). -

$\hat{\sigma}^2 = MSE = \frac{SS_E}{n-2}$ (zuivere schatter van σ^2); $MSR = \frac{SS_R}{1}$. - **Correlatie (Pearson):**

$r = \frac{S_{xY}}{\sqrt{S_{xx}S_{YY}}}$, en voor enkelvoudige regressie $R^2 = r^2$. (Let op: correlatie $\neq$ causaliteit; pas op voor confounding.)

B. Inferentie in (enkelvoudige) regressie

Verdelingen: $\hat{\beta}_1 \sim N\left(\beta_1, \frac{\sigma^2}{S_{xx}}\right)$, $\hat{\beta}_0 \sim N\left(\beta_0, \sigma^2\left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}\right)\right)$.

t-toets helling / intercept (df = $n-2$):

$$t = \frac{\hat{\beta}_1 - \beta_{1,0}}{\sqrt{MSE/S_{xx}}}, \quad t = \frac{\hat{\beta}_0 - \beta_{0,0}}{\sqrt{MSE\left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}\right)}}$$

F-toets significantie regressie ($H_0: \beta_1 = 0$, "regressie nutteloos"):

$$F = \frac{MSR}{MSE} \sim F_{1, n-2} \quad (\text{algemeen } F_{k, n-k-1})$$

De t-toets op β_1 en deze F-toets zijn equivalent.

CI voor helling/intercept: $\hat{\beta}_1 \pm t_{1-\alpha/2, n-2} \sqrt{\frac{MSE}{S_{xx}}}$; $\hat{\beta}_0 \pm t_{1-\alpha/2, n-2} \sqrt{MSE\left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}\right)}$.

CI voor de gemiddelde respons in x_0 ($\hat{Y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0$):

$$\hat{Y}_0 \pm t_{1-\alpha/2, n-2} \cdot se(\hat{Y}_0), \quad se(\hat{Y}_0) = \sqrt{MSE\left(\frac{1}{n} + \frac{(\bar{x} - x_0)^2}{S_{xx}}\right)}$$

Predictie-interval (PI) voor een nieuwe waarneming in x_0 (let op de extra +1, dus breder dan de CI):

$$\hat{Y}_0 \pm t_{1-\alpha/2, n-2} \cdot se(e_0), \quad se(e_0) = \sqrt{MSE\left(1 + \frac{1}{n} + \frac{(\bar{x} - x_0)^2}{S_{xx}}\right)}$$

C. Meervoudige lineaire regressie

$$Y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_k x_{ki} + \varepsilon_i \quad (k + 2 \text{ vrije parameters: } k+1 \text{ coëff.} + \sigma)$$

- $R^2 = \frac{SS_R}{SS_T}$ stijgt altijd bij toevoegen van een variabele -> gebruik **aangepaste** R^2 om modellen te vergelijken:

$$R_{adj}^2 = 1 - (1 - R^2) \frac{n-1}{n-k-1} \quad (k = \text{aantal x-variabelen})$$

> De slide schrijft hier $n-k-2$, maar geverifieerd tegen de Excel-output (15 obs, $k=2 \Rightarrow R_{adj}^2 = 0,9599$) is de noemer $n-k-1$. Gebruik $n-k-1$. - $\hat{\sigma} = \sqrt{MSE} = \sqrt{\frac{SS_E}{n-k-1}}$ (standaardfout van de voorspelling); F-toets model: $F = \frac{MSR}{MSE} \sim F_{k, n-k-1}$.

D. Model-adequaatheid

Residuen $e_i = Y_i - \hat{Y}_i$ als proxy voor de fouten ε_i . Visueel checken: constante variantie? normaal verdeeld? Plots: residuen vs. gefitte/x-waarden (geen patroon), normal-probability-plot (op diagonaal), scale-location (meeste binnen $-2..2$). Remedies: andere/extra x-variabelen, respons-transformatie ($\sqrt{y}$, $\ln y$, $1/y$). Outliers aan de rand van het x-bereik = **influential observations** (beïnvloeden de helling sterk).

E. One-way ANOVA (één factor A , a levels, n replicaten)

- **Means-model:** $Y_{ij} = \mu_i + \varepsilon_{ij}$; **effects-model:** $Y_{ij} = \mu + \tau_i + \varepsilon_{ij}$ met $\sum_i \tau_i = 0$, $\varepsilon_{ij} \sim N(0, \sigma^2)$.
- Groepsgemiddelde $\bar{Y}_{i.} = \frac{1}{n} \sum_j Y_{ij}$; grootgemiddelde $\bar{Y}_{..} = \frac{1}{an} \sum_i \sum_j Y_{ij}$.

Bron	SS	df	MS
Treatment (between)	$SS_{Tr} = n \sum_i (\bar{Y}_{i.} - \bar{Y}_{..})^2$	$a - 1$	$MS_{Tr} = \frac{SS_{Tr}}{a-1}$
Error (within)	$SS_E = \sum_i \sum_j (Y_{ij} - \bar{Y}_{i.})^2$	$a(n-1)$	$MS_E = \frac{SS_E}{a(n-1)}$
Totaal	$SS_T = \sum_i \sum_j (Y_{ij} - \bar{Y}_{..})^2$	$an - 1$	

$$SS_T = SS_{Tr} + SS_E, \quad F = \frac{MS_{Tr}}{MS_E} \sim F_{a-1, a(n-1)}$$

Verwerp $H_0 (\mu_1 = \dots = \mu_a)$ als $F > F_{1-\alpha, a-1, a(n-1)}$. Rekenvorm: $SS_T = \sum y_{ij}^2 - \frac{y_{..}^2}{N}$, $SS_{Tr} = \sum_i \frac{y_{i.}^2}{n} - \frac{y_{..}^2}{N}$ (met $N = an$). Welke gemiddelden verschillen? -> post-hoc, bv. **Fisher's LSD**.

Wat betekent ANOVA eigenlijk? Ondanks de naam "analyse van variantie" toetst ANOVA of de groepsgemiddelden verschillen - maar het doet dat door *varianties* te vergelijken. Kernidee: splits de totale spreiding van de data in twee delen: - **tussen de groepen** (SS_{Tr}): hoe ver liggen de groepsgemiddelden $\bar{Y}_{i.}$ uit elkaar (het mogelijke effect van de factor); - **binnen de groepen** (SS_E): hoeveel spreiding zit er rond elk groepsgemiddelde (de zuivere toevalsruis).

De F-ratio vergelijkt beide: $F = \frac{MS_{Tr}}{MS_E} = \frac{\text{spreiding tussen groepen}}{\text{spreiding binnen groepen}}$. - Als de factor géén effect heeft (H_0), schatten teller en noemer allebei dezelfde σ^2 -> $F \approx 1$. - Als de

factor wél een effect heeft, wordt MS_{Tr} opgeblazen door de echte verschillen tussen de gemiddelden $\rightarrow F \gg 1$.

De toets vraagt dus: “is de spreiding tussen de groepen groter dan wat je door puur toeval zou verwachten?” ANOVA veralgemeent zo de tweesteekeproeven-t-toets naar méér dan twee groepen, en is wiskundig een speciaal geval van regressie (met dummy-variabelen voor de factorniveaus) - vandaar dat exact dezelfde SS-ontbinding $SS_T = SS_{Tr} + SS_E$ geldt als bij regressie ($SS_T = SS_R + SS_E$).

F. DOE - principes

- Doel: bepalen welke factoren x de respons y het sterkst beïnvloeden, en bij welke instellingen y gewenst / variabiliteit minimaal is.
- **Externe (“nuisance”) factoren** beheersen:

	bekend	onbekend
controleerbaar	Blocking	-
oncontroleerbaar	-	Randomisatie

- **Confounding:** als het effect van factor A niet te onderscheiden is van B (100% gecorreleerd) $\rightarrow$ ontwerp deugt niet. Volledig-factorieel ontwerp vermijdt confounding en maakt interacties schatbaar.

G. 2^k factorieel ontwerp (k factoren, 2 levels, n replicaten)

- **Codering** van levels naar $-1/+1$ (translatie + herschaling; interactiekolommen = product van factorkolommen).
- **Effect** van factor/interactie Q :

$$[Q] = \bar{y}_{Q+} - \bar{y}_{Q-} = (\text{gem. respons bij } +1) - (\text{gem. respons bij } -1)$$

- **Contrasten** (voorbeeld 2^2 , met lottotalen $(1), a, b, ab$):

$$C_A = a + ab - b - (1), \quad C_B = ab + b - a - (1), \quad C_{AB} = ab + (1) - a - b$$

- **Algemeen 2^k :** Effect = $\frac{\text{Contrast}}{n 2^{k-1}}$ en $SS = \frac{(\text{Contrast})^2}{n 2^k}$ (voor 2^2 : $SS = \frac{C^2}{4n}$).
- **Significantie van een effect:** standaardfout $se(\text{effect}) = \sqrt{\frac{\hat{\sigma}^2}{n 2^{k-2}}}$; benaderend 95%-CI effect $\pm 2 \cdot se(\text{effect})$. Bevat de CI nul $\rightarrow$ factor niet significant ($\alpha = 0,05$).
- **Single replicate / sparsity-of-effects:** bij grote k slechts 1 replicaat; pool hogere-orde interacties in de foutterm (een volledig model is “saturated”: geen df over voor inferentie).
- **Fractioneel ontwerp 2^{k-p} :** halve fractie = 2^{k-1} runs, gedefinieerd door een generator/relatie (bv. $I = ABC$); leidt tot aliasing van effecten.

H. Relevante Excel-functies

(Nederlandse Excel: puntkomma's; WAAR/ONWAAR = TRUE/FALSE. De Analysis ToolPak geeft kant-en-klare tabellen.)

Doel	Excel-functie
Helling / intercept	=SLOPE(y;x), =INTERCEPT(y;x)
R^2 / correlatie	=RSQ(y;x), =CORREL(x;y) (of =PEARSON(x;y))
Volledige regressie-output (matrixformule)	=LINEST(y;x;WAAR;WAAR) $\rightarrow$ coeff., SE's, R^2 , F, df, SS_R , SS_E
Standaardfout van de schatting ($\sqrt{MSE}$)	=STEYX(y;x)
Voorspelling $\hat{Y}$ in x_0	=FORECAST.LINEAR(x0;y;x) of =TREND(...)

Doel	Excel-functie
S_{xx} (kwadratensom afwijkingen)	=DEVSQ(x)
F-toets kritieke waarde / p-waarde	=F.INV.RT(α ;df1;df2) ; =F.DIST.RT(F;df1;df2)
t voor coëfficiënten (kritiek / p)	=T.INV.2T(α ;df) ; =T.DIST.2T(ABS(t);df)
Kant-en-klare analyse (ToolPak)	Gegevens > Gegevensanalyse > "Regressie", "ANOVA: één factor", "ANOVA: twee factoren met/zonder replicatie"

Les 4 - SPC & proces-capabiliteit (12/06)

Bestanden: *deck Capabiliteit - SPC (Grymonprez), Control charts - constants, SPC-tabellen, oefeningen. Twee blokken: (1) capabiliteit, (2) regelkaarten.*

A. Normaalverdeling & sigma-niveau (recap)

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1); \quad P[\mu \pm 1\sigma] \approx 68\%, \quad P[\mu \pm 2\sigma] \approx 95\%, \quad P[\mu \pm 3\sigma] \approx 99,73\%$$

Standaardfout van het gemiddelde (CLT): $\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$ (spreiding van steekproefgemiddelden < spreiding van individuele punten).

Sigma-capability tabel (met de empirische $\pm 1,5\sigma$ lange-termijn shift van Motorola):

Sigma-niveau	DPMO	% Yield
2	308.537	69,15%
3	66.807	93,32%
4	6.210	99,38%
5	233	99,98%
6	3,4	99,99966%

B. Discrete capabiliteit (telgegevens)

Met D = aantal defecten, N = aantal eenheden (units), O = opportuniteiten per eenheid:

$$DPU = \frac{D}{N}, \quad DPO = \frac{D}{N \cdot O}, \quad DPMO = 10^6 \cdot \frac{D}{N \cdot O}, \quad Yield = 1 - DPO$$

PPM = parts per million; omrekenen van % naar PPM: $\times 10.000$.

C. Proces-capabiliteit (continu): C_p, C_{pk}, P_p, P_{pk}

$$C_p = \frac{USL - LSL}{6\sigma}$$

$$C_{pk} = \min\left(\frac{USL - \mu}{3\sigma}, \frac{\mu - LSL}{3\sigma}\right)$$

- C_p = breedte distributie vs. tolerantie (de *potentiële* capability; houdt geen rekening met ligging). C_{pk} houdt ook rekening met de **ligging** van μ (de "k" = Japans voor off-center). Steeds $C_{pk} \leq C_p$; gelijk enkel als perfect gecentreerd. - **Korte termijn** C_p/C_{pk} (within-variation, "white noise") vs. **lange termijn** P_p/P_{pk} (overall variation, "black noise" - wat de klant ervaart): zelfde formules

maar met σ_{LT} . - σ schatten uit de regelkaart: $\hat{\sigma} = \frac{\bar{R}}{d_2}$ (of $\hat{\sigma} = \frac{\bar{s}}{c_4}$).

C_p	Oordeel	Uitval (gecentreerd)
< 1	niet capabel	> 2700 ppm
$= 1$	net capabel ($USL - LSL = 6\sigma$)	2700 ppm (99,73%)
$\geq 1,33$	aanvaardbaar ($= 8\sigma$)	~ 63 ppm (99,9937%)
$\geq 1,67$	goed ($= 10\sigma$)	$\sim 0,57$ ppm
$= 2$	6-sigma niveau (ST)	enkele ppb

6-sigma technisch: $C_p = 2$, $C_{pk} = 1,5$ (door de $\pm 1,5\sigma$ shift) $\Rightarrow 3,4$ DPMO. > Vuistregel: als C_p slecht is, bereken C_{pk} niet. C_{pk} verbeteren is meestal makkelijk (centreren/kalibreren, operator); C_p verbeteren is moeilijk (veel factoren, proces-engineer).

Uitgewerkt voorbeeld. Gefreesd stuk, specs 100 ± 10 (dus $LSL = 90$, $USL = 110$). Regelkaart onder controle: $\bar{X} = 104$, $\bar{R} = 9,30$, $n = 5$. - $\hat{\sigma} = \frac{\bar{R}}{d_2} = \frac{9,30}{2,326} \approx 4$. - $C_p = \frac{110 - 90}{6 \cdot 4} = \frac{20}{24} = 0,83$ (niet capabel). - $C_{pk} = \min\left(\frac{110 - 104}{3 \cdot 4}, \frac{104 - 90}{3 \cdot 4}\right) = \min(0,5; 1,17) = 0,5$. - Centreren ($\mu = 100$) zou C_{pk} optrekken tot $C_p = 0,83$, maar het proces blijft niet capabel: $3\sigma = 12 > 10$, dus zelfs gecentreerd valt output buiten de specs - de **spreiding** moet omlaag.

D. Stabiliteit: common vs. special causes

- **Common cause** (within, korte termijn): toevallige, voorspelbare variatie - proces is stabiel; verantwoordelijkheid management (proces-engineer).
- **Special cause:** (a) *systematische* oorzaak = geleidelijk verloop (bv. slijtage); (b) *aanwijsbare* oorzaak = abrupte wijziging (nieuwe machine, ander materiaal). Verantwoordelijkheid operator.
- **Stabiel proces** = verdeling van proceskenmerken constant over de tijd ($N(\mu_0, \sigma_0)$ met μ_0, σ_0 constant). Stabiel $\neq$ capabel: een stabiel proces voldoet niet noodzakelijk aan de klantspecs.

E. SPC - regelkaarten

- **Regelgrenzen (UCL/LCL)** = $\pm 3\sigma$ van het gemiddelde = *voice of the process*; **tolerantiegrenzen (USL/LSL)** = *voice of the customer*. Niet verwarren - regelgrenzen staan op de controlekaart, specs op het histogram.

$\bar{X}$ -kaart (bewaakt het gemiddelde μ_0):

$$CL = \bar{X}, \quad UCL/LCL = \bar{X} \pm 3\sigma_{\bar{x}} = \bar{X} \pm 3\frac{\sigma}{\sqrt{n}} = \bar{X} \pm A_2\bar{R} \quad (\text{of } \pm A_3\bar{s})$$

R -kaart (bewaakt de spreiding, kleine n): $CL = \bar{R}$, $UCL = D_4\bar{R}$, $LCL = D_3\bar{R}$.

s -kaart (spreiding, aanbevolen voor $n > 10$): $CL = \bar{s}$, $UCL = B_4\bar{s}$, $LCL = B_3\bar{s}$.

Controlekaart-constanten (standaard ASTM-tabel, functie van subgroepgrootte n):

n	A_2	A_3	d_2	D_3	D_4	B_3	B_4	c_4
2	1,880	2,659	1,128	0	3,267	0	3,267	0,7979
3	1,023	1,954	1,693	0	2,574	0	2,568	0,8862
4	0,729	1,628	2,059	0	2,282	0	2,266	0,9213
5	0,577	1,427	2,326	0	2,114	0	2,089	0,9400
6	0,483	1,287	2,534	0	2,004	0,030	1,970	0,9515
7	0,419	1,182	2,704	0,076	1,924	0,118	1,882	0,9594
8	0,373	1,099	2,847	0,136	1,864	0,185	1,815	0,9650
9	0,337	1,032	2,970	0,184	1,816	0,239	1,761	0,9693
10	0,308	0,975	3,078	0,223	1,777	0,284	1,716	0,9727

Verbanden: $A_2 = \frac{3}{d_2\sqrt{n}}$, $A_3 = \frac{3}{c_4\sqrt{n}}$. Voor $n > 10$ is de s -kaart efficiënter; voor kleine n of manueel werk is R eenvoudiger.

Out-of-control detectie - Western Electric-regels (1 of meer treedt op = special cause): 1. 1 punt buiten de 3σ -grenzen (zone A); 2. 2 van 3 opeenvolgende punten buiten 2σ aan dezelfde kant; 3. 4 van 5 opeenvolgende punten buiten 1σ aan dezelfde kant; 4. 8 opeenvolgende punten aan dezelfde kant van de centerlijn (run/trend).

Twee fouten bij interpretatie: **tampering** (reageren op common cause $\rightarrow$ vergroot variatie) en **underreacting** (special cause missen). Belangrijk: *proces onder controle $\neq$ proces voldoet aan klanteisen*.

F. Relevante Excel-functies

(Nederlandse Excel; WAAR/ONWAAR.)

Doel	Excel-functie
% uitval / yield onder spec	=NORM.DIST(LSL; μ ; σ ;WAAR) (linkerstaart); rechterstaart = 1-NORM.DIST(USL; μ ; σ ;WAAR)
Standaardnormaal (Z naar p)	=NORM.S.DIST(z;WAAR)
Sigma-niveau uit yield (inverse)	=NORM.S.INV(yield)
Gemiddelde / std subgroep	=AVERAGE(...), =STDEV.S(...)

Rekenwijze uitval: standaardiseer de speciëmet naar $Z = \frac{\text{spec}-\mu}{\sigma}$ en lees de staartkans af (let op één- vs. tweezijdig: tel beide staarten op bij een tweezijdige specificatie).

Les 5 - MSA / Gage R&R & simulatie (19/06)

Bestanden: *Otto Measurement System Analysis + GRR study; De Vuyst Simulation*. Twee losse delen.

Deel I - Measurement System Analysis (Ottoy)

A. Meetsysteem & het SWIPE-foutmodel

Een **meting** = toekenning van een getal (+ eenheid) aan een eigenschap, via vergelijking met een **referentie/standaard** (de ware waarde is onkenbaar; de referentiewaarde is het surrogaat). Het **meetsysteem** = geheel van gauge, methode, operator, software, omgeving. Een meetproces is zelf een proces dat getallen produceert, dus alle SPC-technieken zijn erop toepasbaar.

Een goed meetsysteem heeft: **adequate discriminatie** (Rule of Tens: discriminatie verdeelt tolerantie/procesvariatie in ≥ 10 delen), **statistische stabiliteit**, en **kleine variabiliteit** t.o.v. tolerantie of procesvariatie.

SWIPE = de zes bronnen van meetvariatie: **S**tandard, **W**orkpiece, **I**nstrument, **P**erson (procedure), **E**nvironment.

B. Terminologie - de meetfout ontleed

Begrip	Definitie	Verwant met
Bias	$\bar{X}$ — ref.waarde - systematische fout	accuracy
Stabiliteit	verandering van bias over tijd	bias
Lineariteit	verandering van bias over het meetbereik	bias

Begrip	Definitie	Verwant met
Repeatability (EV)	spreiding, 1 operator + 1 gauge, zelfde stuk (<i>within</i> -variatie)	precision
Reproducibility (AV)	spreiding tussen operatoren (zelfde gauge/stuk)	operator bias
Consistency	verandering van repeatability over tijd	repeatability
Uniformity	verandering van repeatability over het bereik	repeatability

Geheugensteun: *stabiliteit* : *bias* = *consistency* : *repeatability* (over tijd), en *lineariteit* : *bias* = *uniformity* : *repeatability* (over bereik).

C. Gage R&R & meetsysteem capability/performance

$$\sigma_{GRR}^2 = \sigma_{rep}^2 + \sigma_{repro}^2 \iff GRR = \sqrt{EV^2 + AV^2}$$

$$\sigma_{cap}^2 = \sigma_{lin}^2 + \sigma_{GRR}^2 \quad \sigma_{perf}^2 = \sigma_{cap}^2 + \sigma_{stab}^2 + \sigma_{consist}^2$$

Capability = korte-termijn (lineariteit + GRR); *performance* = voegt stabiliteit + consistency toe (lange termijn).

D. Waargenomen vs. werkelijke procesvariatie + %GRR

De waargenomen variatie bevat de meetfout. Met *o* = observed, *a* = actual, *m* = measurement:

$$\sigma_o^2 = \sigma_a^2 + \sigma_m^2 \iff \frac{1}{C_{p,o}^2} = \frac{1}{C_{p,a}^2} + \frac{1}{C_{p,m}^2}$$

$$\%GRR_{proces} = \frac{6\sigma_m}{6\sigma_o} = \frac{\sigma_m}{\sigma_o} (\times 100\%) \quad \%GRR_{tol} = \frac{6\sigma_m}{TOL} (\times 100\%)$$

Koppeling actual <-> observed C_p (tolerantie-gebaseerde %GRR):

$$C_{p,o} = C_{p,a} \sqrt{1 - (\%GRR \cdot C_{p,o})^2} \iff \frac{1}{C_{p,o}^2} = \frac{1}{C_{p,a}^2} + \%GRR^2$$

Voorbeeld: werkelijke $C_p = 2$. Buy-off-gauge met %GRR = 10% -> waargenomen $C_p = 1,96$; productiegauge met %GRR = 30% -> $C_p = 1,71$ (nog aanvaardbaar); ongekwalificeerde gauge %GRR = 60% -> $C_p \approx 1,2$ (onaanvaardbaar). Het verschil komt volledig van het meetsysteem, niet van procesverslechtering. Historisch werd voor de "volle spreiding" $5,15\sigma$ (99%) gebruikt; nu 6σ (99,73%).

E. Average & range method (de GRR-studie)

k operatoren meten elk *n* stukken *r* keer. Afgeleide grootheden:

$$EV = \bar{R}/d_2 = \bar{R} \cdot K_1, \quad K_1 = 1/d_2 \text{ (subgroepgrootte = } r)$$

$$AV = \sqrt{(\bar{X}_{DIFF} \cdot K_2)^2 - \frac{EV^2}{nr}}, \quad K_2 = 1/d_2^* \text{ (1 subgroep van grootte } k)$$

$$PV = \sqrt{(\bar{R}_p \cdot K_3)^2 - \frac{EV^2}{kr}} \approx \bar{R}_p \cdot K_3, \quad K_3 = 1/d_2^* \text{ (1 subgroep van grootte } n)$$

met $\bar{X}_{DIFF}$ = bereik van de operator-gemiddelden, $\bar{R}_p$ = bereik van de stuk-gemiddelden. Dan:

$$GRR = \sqrt{EV^2 + AV^2}, \quad TV = \sqrt{GRR^2 + PV^2}, \quad \%GRR = \frac{GRR}{TV} \times 100\%$$

ndc (aantal onderscheidbare categorieën) = $1,41 \cdot \frac{PV}{GRR}$ (naar beneden afronden; ≥ 5 gewenst)

d_2 -waarden (voor EV, subgroep = r): $r=2 \rightarrow 1,128$; $r=3 \rightarrow 1,693$; $r=4 \rightarrow 2,059$; $r=5 \rightarrow 2,326$. (De d_2^* voor één subgroep wijken licht af; zie de MSA-tabellen.)

Aanvaardingscriteria %GRR: $\leq 10\%$ = aanvaardbaar · 10-30% = mogelijk aanvaardbaar (afh. van belang/kost) · $> 30\%$ = niet aanvaardbaar.

F. Bias, stabiliteit & lineariteit bepalen

- **Bias:** bias = $\bar{X} - \text{ref.waarde}$; repeatability $\sigma_r = \bar{R}/d_2$. De statistiek $t = \frac{\text{bias}}{\sigma_r \cdot d_2^*/(d_2 \sqrt{gm})}$ volgt een t -verdeling $\rightarrow$ CI voor de ware bias; **significant** als 0 er niet in ligt.
- **Stabiliteit:** meet periodiek een referentiestandaard, plot $\bar{X}/R$ - of $\bar{X}/s$ -kaart over tijd; stabiel = statistische controle.
- **Lineariteit:** meet $g \geq 5$ stukken over het bereik, elk $m \geq 10$ keer; bereken $\text{bias}_{i,j} = m_{i,j} - \text{ref}_i$, regresseer bias op ref.waarde, en toets H_0 : helling = 0. De gauge is lineair als de lijn bias = 0 binnen de betrouwbaarheidsbanden ligt.

G. Meetonzekerheid

$$\text{Ref.waarde} = \text{meting} \pm U, \quad U = k \cdot u_c$$

met U = uitgebreide onzekerheid, k = dekkingsfactor ($k = 2$ voor 95% vertrouwen), u_c = gecombineerde standaardonzekerheid = σ_{meetfout} . Een meetonzekerheid is dus een betrouwbaarheidsinterval voor de referentiewaarde. - **Type A** (via statistiek) en **Type B** (via kalibratiecertificaten, specs, gezond verstand). - **Propagatie** bij $y = f(x)$: $u(y) \approx |f'(x)| \cdot u(x)$. Voor $y = x^2$: $u(x^2) \approx 2x u(x)$, dus de **relatieve** onzekerheid verdubbelt. (Bv. $x = 5 \pm 0,1 \Rightarrow x^2 = 25 \pm 1$.) - **Combineren** (kwadratuur): som/verschil $u_c(x \pm y) = \sqrt{u^2(x) + u^2(y)}$; product/quotiënt $\frac{u_c(xy)}{|xy|} = \sqrt{\left(\frac{u(x)}{x}\right)^2 + \left(\frac{u(y)}{y}\right)^2}$.

H. Probable error, GPC & discriminatie

- **Probable Error:** $PE \approx 0,67 \sigma_m$ (= 75%-kwantiel min gemiddelde); $\approx 50\%$ van de metingen ligt binnen $\mu \pm PE$. Gebruikt om specs PE-verbreed-/versmald te corrigeren voor meetfout.
- **Gauge Performance Curve (GPC):** kans om een stuk met referentiewaarde $\bar{X}_r$ te aanvaarden, $\beta(\bar{X}_r) = \Phi(\cdot) - \Phi(\cdot)$. Analooq aan de OC-curve uit Les 2.
- **Inadequate discriminatie** doet een $\bar{X}/R$ -kaart vals "out-of-control" lijken; vuistregel (subgroep = 2): ≤ 3 mogelijke bereik-waarden binnen de regelgrenzen = te grove meeteenheid.

I. ANOVA-methode voor GRR

Twee-weg ANOVA (operator $\times$ stuk) ontbindt SS_{totaal} ; de **error-MS** = EV^2 (repeatability), de factor-MS leveren AV/PV. Voordelen boven average&range: kan **interacties** (operator $\times$ stuk) schatten, splitst reproducibility verder op (tussen operatoren/instrumenten/...), en geeft nauwkeuriger schattingen.

Deel II - Simulatie van stochastische systemen (De Vuyst)

A. Simulatie, systeem & model

Simulatie = "de kunst en wetenschap een proces of systeem na te bootsen om te experimenteren en evalueren." Een **systeem** evolueert in tijd, beïnvloed door input $\rightarrow$ meetbare output. Een **model** is een abstractie (wiskundige beschrijving, vaak stochastisch). Kies een model naar zijn doel - de *holy trinity* **systeem - doel - model**. "All models are wrong, but some are useful" (Box). Twee

manieren om een queue op te lossen: **wachtrijtheorie** (analytisch, exact) of **Monte Carlo / DES** (simulatie, beperkte precisie).

B. M/M/1/K-wachtrij (analytisch)

$M/M/1/K$: exponentiële tussenaankomsttijden (gem. $1/\lambda$, Poisson-aankomsten), exponentiële bedieningstijd (gem. $1/\mu$), 1 server, FIFO, capaciteit K . Met bezettingsgraad $\rho = \lambda/\mu < 1$:

$$\pi_j = \Pr[L = j] = \frac{\rho^j(1 - \rho)}{1 - \rho^{K+1}}, \quad j = 0, \dots, K$$

$$E[L] = \sum_{j=0}^K j \pi_j, \quad E[W] = \frac{E[L]}{\lambda(1 - \pi_K)} \text{ (Little, gecorrigeerd voor verlies)}$$

C. Het Poisson-proces

Een puntproces met intensiteit λ waarbij de tussentijden iid $T \sim \text{Expon}(\lambda)$ zijn. - **Onafhankelijke increments**: $X(t) - X(s) \sim \text{Poiss}(\lambda(t - s))$. - **Superpositie**: twee onafhankelijke Poisson-processen $\lambda_1, \lambda_2 \rightarrow$ samen Poisson met $\lambda_1 + \lambda_2$. - **Thinning**: elk event behouden met kans $p \rightarrow$ Poisson met $p\lambda$.

D. Schattingstheorie

Voor een schatter $\hat{\theta}$ van θ :

$$\text{bias} = E[\hat{\theta}] - \theta, \quad \text{MSE}(\hat{\theta}) = \text{bias}^2 + \text{Var}[\hat{\theta}]$$

Accuracy = tegengestelde van bias (hoe dicht bij de waarde); **precision** = $1/\text{variantie}$ (efficiëntie). Een schatter is **consistent** als $\hat{\theta}_n \rightarrow \theta$ in kans voor $n \rightarrow \infty$. Onthoud: zuiverheid (bias) en consistentie zijn los van elkaar - $\bar{X}$ is beide; $\frac{X_1 + X_2 + X_3}{3}$ is zuiver maar niet consistent.

E. Monte Carlo estimatie (MCE)

Elke integraal is een verwachtingswaarde: $\theta = \int_{\Omega} h(x)f(x) dx = E[h(X)]$. De **MC-schatter**:

$$\hat{\theta}_n = \frac{1}{n} \sum_{i=1}^n h(X_i) \quad (\text{zuiver én consistent})$$

$$\text{Var}[\hat{\theta}_n] = \frac{\text{Var}[h(X)]}{n}, \quad \text{Dev}[\hat{\theta}_n] = \frac{\text{Dev}[h(X)]}{\sqrt{n}}$$

De fout daalt dus traag, als $1/\sqrt{n}$. Betrouwbaarheidsinterval via CLT ($\hat{\theta}_n$ wordt normaal):

$$\hat{\theta}_n + z_{\alpha/2} \frac{\text{Dev}[h(X)]}{\sqrt{n}} < \theta < \hat{\theta}_n + z_{1-\alpha/2} \frac{\text{Dev}[h(X)]}{\sqrt{n}}$$

Voorbeeld (π schatten): trek punten $(X, Y) \sim \text{Unif}(-1, 1)$, $h = 1$ als $X^2 + Y^2 \leq 1$; dan $\hat{\theta}_n \rightarrow \theta = \pi/4$. Een puntschatting zonder CI is nutteloos - geef altijd een betrouwbaarheidsinterval.

F. Steady-state & discrete-tijd-wachtrij

- **Finite horizon** = eindig aantal toevalsvariabelen (bv. $E[\max(X_1, \dots, X_k)]$); **infinite horizon** = oneindig veel (over tijd) $\rightarrow$ vraag of er een **steady state** bestaat.

- Discrete-tijd-queue (capaciteit C , aankomsten A_n , bediening $B_n \sim \text{Bern}(q)$):

$$Q_{n+1} = \min(C, \max(Q_n - B_n, 0) + A_n)$$

$$\hat{J} = \frac{1}{N} \sum_{n=1}^N Q_n = \frac{1}{N} \sum_{j=0}^C h_j \cdot j \quad (\text{schatte voor } E[Q], h_j = \text{aantal slots met } Q = j)$$

- **Warm-up:** gooi het begin van het traject weg (niet representatief voor steady state). Voor $C = \infty$ bestaat een evenwicht **enkel** als $\lambda < \mu$; bij $\lambda \geq 1$ bestaat $E[Q]$ niet.

G. Discrete-Event Simulation (DES)

Centraal idee: haal alle tijd-informatie uit de toestand en stop ze in een **agenda**. De toestand = **globale variabelen** (queue-grootte, status busy/idle, ...) + **agenda** (lijst van toekomstige events: tijdstip + type). Het programma springt telkens naar het event met de kleinste tijd-tag en roept een **event-handler** aan (update toestand, update statistieken, genereer nieuwe events); de **Clock** bevat de tijd van het laatst behandelde event. - **Time-driven** (vaste stap Δ) vs. **event-driven** (tijd springt van event naar event, $t_k = t_{k-1} + \tau_k$ - veel efficiënter). - *Voorbeeld (reneging queue)*: items met een levensduur verlaten de rij als die verstrijkt vóór bediening. Stabiël ook als $\lambda > \mu$ (door expiraties). Balans: aankomstrate = expiratie + completierate = vertrekkrate. Nuttige doorvoerschatte:

$$\hat{\theta} = \frac{N_C(T_{sim})}{T_{sim}} \quad (N_C = \text{aantal voltooide items})$$

Drie event-types (Arrival, Expiration, Completion); een expiratie-event wordt genegeerd als het item ondertussen al in bediening is.

Root - Voorbeeldexamen: formules per vraag

Op basis van het examen van 9/10/2025 + worked solutions. Per vraag de kernformule(s), het antwoord en de relevante les.

Vraag 1 (2,5) - Interpretatie van statistische resultaten

- **(a)** Statistische significantie $\neq$ praktische/economische significantie: een p-waarde zegt niets over effectgrootte of kost (bij grote n wordt zelfs een micro-effect "significant"). Beslissing vergt effectgrootte + kosten-batenanalyse. **Niet correct.**
- **(b)** Een 95%-CI $[1,4\%; 2,2\%]$ ligt volledig boven 1% $\rightarrow$ proces kan geen $< 1\%$ halen. **Correct.**
- **(c)** CI-halfbreedte $= z \cdot \frac{\sigma}{\sqrt{n}} \rightarrow 0$ als $n \rightarrow \infty$; geen theoretische ondergrens (in theorie elke nauwkeurigheid). **Correct.**
- **(d)** Cluster sampling is een *selectie*-methode; non-response treedt *na* selectie op. Geen enkel design immuniseert daartegen. **Niet correct.**
- **(e)** Tweezijdige toets op niveau $\alpha \Leftrightarrow (1 - \alpha)$ -CI: $1\% \leftrightarrow 99\%$. **Correct.**

Vraag 2 (3) - F-toets voor twee varianties

"M1 nauwkeuriger dan M2" $\Leftrightarrow \sigma_1^2 < \sigma_2^2 \Leftrightarrow \sigma_2^2/\sigma_1^2 > 1$. Eénzijdige 95%-ondergrens:

$$\frac{\sigma_2^2}{\sigma_1^2} \geq \frac{s_2^2}{s_1^2} \cdot F_{0,05}(n_1-1; n_2-1), \quad F_{0,05}(9; 14) = =F.INV(0,05;9;14) = 0,3305$$

Ligt de ondergrens $L > 1 \rightarrow$ vermoeden bevestigd (M1 nauwkeuriger). (Les 2.C/D.)

Vraag 3 (2) - Proces-capabiliteit

$$C_p = \frac{USL - LSL}{6\sigma} = \frac{60}{60} = 1,0, \quad C_{pk} = \min\left(\frac{20}{30}, \frac{40}{30}\right) = 0,67$$

Proces is 10 mm te hoog gecentreerd ($\mu = 1440$ vs. centrum 1430). **% uitval:** $Z_U = \frac{1460-1440}{10} = +2 \rightarrow 2,28\%$; $Z_L = -4 \rightarrow \approx 0$; totaal $\approx 2,28\%$ ($=1 - \text{NORM.DIST}(1460; 1440; 10; \text{WAAR})$). **Verbeteren:** (1) hercentreren ($\mu \rightarrow 1430$), (2) σ verlagen. **6 σ -criterium:** max **3,4** DPMO = 0,00034% (met 1,5 σ -drift). (Les 4 + Les 2 DPMO.)

Vraag 4 (1,5) - Regelkaarten

- **Normaliteit/gemiddelden:** door de **CLT** zijn subgroepgemiddelden $\bar{x}$ bij benadering normaal, ook als de individuele metingen dat niet zijn $\rightarrow$ grenzen op $\mu \pm 3\sigma$ (99,73%).
- **Detecteerbaar: bijzondere (aanwijsbare) oorzaken** (signaal: punt buiten grenzen, run, trend); common cause = ruis binnen de grenzen (niet op reageren = tampering).
- **Range als beste schatter:** bij **kleine subgroepen** ($n \lesssim 8-10$): de range is dan bijna even efficiënt als s en simpeler; voor grotere subgroepen is de s -kaart beter. (Les 4.)

Vraag 5 (4) - Confusion matrix & bias-variance

Accuracy = $\frac{TP + TN}{\text{totaal}}$. A: train 96,5% / test 61,7% (kloof ~ 35) $\rightarrow$ **hoge variantie** (overfit). B: train 74% / test 61,7% $\rightarrow$ **hoge bias** (underfit, fit zelfs training slecht). C: train 85% / test **69,2%** (beste test) $\rightarrow$ **optimaal**. Hoge bias in een boom verhelpen: **complexer maken** (grotere diepte, minder pruning, lagere min. samples/split, meer features). (ML-sectie in Les 1.)

Vraag 6 (4) - Verdelingen & variantie

Var	Familie	$E[\cdot]$
B (bestellingen/week)	Poisson	175,3
T (tijd tussen bestellingen)	exponentieel	1/175,3
C (capaciteit μF)	normaal	820
X (conform j/n)	Bernoulli	0,95
D (niet-conform per lot)	binomiaal (100; 0,05)	$np = 5$

iid onrealistisch: B (weken niet identiek verdeeld: seizoen/promo), en D/C (stukken van dezelfde lijn correleren $\rightarrow$ defecten clusteren bij procesdrift). **Var berekenen:** binomiaal $\text{Var}[D] = np(1-p) = 100 \cdot 0,05 \cdot 0,95 = 4,75$. Normaal $\text{Var}[C] = \sigma^2$ met σ uit de staartkans: $P(C < 720) = 5\% \Rightarrow \frac{720-820}{\sigma} = -1,645 \Rightarrow \sigma = 60,8 \Rightarrow \text{Var}[C] \approx 3696 \mu F^2$. (Les 1 verdelingen.)

Vraag 7 (3) - Regressielijn & causale interventie

$f(x) = E[S \mid T = x]$ = voorwaardelijk gemiddelde = regressielijn door het verticale centrum van de puntenwolk. - **do(T=730), S $\rightarrow$ T** (interventie op het *gevolg*): S behoudt zijn **marginale** verdeling $\rightarrow$ bolletjes verticaal over de hele S-range. - **do(T=730), T $\rightarrow$ S** (interventie op de *oorzaak*): S volgt $P(S \mid T = 730)$ $\rightarrow$ kruisjes dicht rond $E[S \mid T = 730]$.

Kern: conditioneren (zien) $\neq$ interveniëren (doen); dezelfde scatter past bij beide causale richtingen, dus je kan causaliteit niet uit correlatie aflezen. (Les 1 causaliteit.)

Volledig Excel-formularium

Nederlandse Excel: argumenten gescheiden door **puntkomma's**; WAAR/ONWAAR = TRUE/FALSE. "cumulatief" = WAAR voor de CDF (kans $\leq$), ONWAAR voor de kansdichtheid/-massa in één punt.

Beschrijvende statistiek

Doel	Functie
Gemiddelde	=AVERAGE(bereik)
Mediaan / modus	=MEDIAN(bereik) ; =MODE.SNGL(bereik)
Std.afw. steekproef / populatie	=STDEV.S(bereik) ; =STDEV.P(bereik)
Variantie steekproef / populatie	=VAR.S(bereik) ; =VAR.P(bereik)
Kwadratensom $\sum (x - \bar{x})^2 (S_{xx})$	=DEVSQ(bereik)
Range	=MAX(bereik) - MIN(bereik)
Aantal / percentiel	=COUNT(bereik) ; =PERCENTILE.INC(bereik;p)

Normale verdeling

Doel	Functie
CDF $P(X \leq x)$	=NORM.DIST(x;μ;σ;WAAR)
Kansdichtheid (pdf)	=NORM.DIST(x;μ;σ;ONWAAR)
Inverse (kwantiel)	=NORM.INV(p;μ;σ)
Standaardnormale CDF $\Phi(z)$	=NORM.S.DIST(z;WAAR)
Standaardnormale inverse	=NORM.S.INV(p) -> =NORM.S.INV(0,975) = 1,96
Random trekking $N(\mu, \sigma)$	=NORM.INV(RAND();μ;σ)
Fractie conform tussen specs	=NORM.DIST(USL;μ;σ;WAAR) - NORM.DIST(LSL;μ;σ;WAAR)

t-verdeling (gemiddelde, regressie-coëfficiënten)

Doel	Functie
Kritieke t eenzijdig	=T.INV(α;df)
Kritieke t tweezijdig	=T.INV.2T(α;df)
p-waarde links / rechts	=T.DIST(t;df;WAAR) ; =T.DIST.RT(t;df)
p-waarde tweezijdig	=T.DIST.2T(ABS(t);df)
t-toets ineens (2 reeksen)	=T.TEST(reeks1; reeks2; zijden; type)
Halve CI-breedte gemiddelde	=CONFIDENCE.T(α;s;n) (onbekende σ) ; =CONFIDENCE.NORM(α;σ;n) (gekende σ)

χ^2 -verdeling (variantie)

Doel	Functie
Kritieke χ^2 rechts / links	=CHISQ.INV.RT(α;df) ; =CHISQ.INV(α;df)
p-waarde (rechterstaart)	=CHISQ.DIST.RT(χ^2 ;df)

F-verdeling (twee varianties, ANOVA, regressie)

Doel	Functie
Kritieke F linkerstaart (variantieverhouding-CI)	=F.INV(α;df1;df2) -> =F.INV(0,05;9;14) = 0,3305
Kritieke F rechterstaart	=F.INV.RT(α;df1;df2)
p-waarde (rechterstaart)	=F.DIST.RT(F;df1;df2)
F-toets twee varianties ineens	=F.TEST(reeks1; reeks2)

Discrete verdelingen (acceptance sampling)

Doel	Functie
Binomiaal $P(d)$ of $P(\leq d)$	=BINOM.DIST(d;n;pi;cumulatief)
Poisson	=POISSON.DIST(x;lambda;cumulatief)
Hypergeometrisch (eindige populatie)	=HYPGEOM.DIST(d;n;D;N;cumulatief)

Regressie & correlatie

Doel	Functie
Helling $\hat{\beta}_1$ / intercept $\hat{\beta}_0$	=SLOPE(y;x) ; =INTERCEPT(y;x)
R^2 / correlatie r	=RSQ(y;x) ; =CORREL(x;y) (of =PEARSON(x;y))
Volledige output (matrixformule)	=LINEST(y;x;WAAR;WAAR) -> coëff., SE's, R^2 , F , df, SS_R , SS_E
Standaardfout schatting $\sqrt{MSE}$	=STEYX(y;x)
Voorspelling $\hat{Y}$ in x_0	=FORECAST.LINEAR(x0;y;x) of =TREND(y;x;x0)
ANOVA / regressie-tabellen	Analysis ToolPak: Data > Gegevensanalyse

Capability, sigma-niveau & DPMO

Doel	Functie
% uitval onder LSL / boven USL	=NORM.DIST(LSL;mu;sigma;WAAR) ; =1-NORM.DIST(USL;mu;sigma;WAAR)
Totale uitval (2-zijdig)	=NORM.DIST(LSL;mu;sigma;WAAR)+(1-NORM.DIST(USL;mu;sigma;WAAR))
C_p	=(USL-LSL)/(6*sigma)
C_{pk}	=MIN((USL-mu)/(3*sigma);(mu-LSL)/(3*sigma))
DPMO uit sigma-niveau k ($1,5\sigma$ -drift)	=(1-NORM.S.DIST(k-1,5;WAAR))*1000000
Sigma-niveau (KT) uit DPMO	=NORM.S.INV(1-DPMO/1000000)+1,5
Sigma-niveau uit yield	=NORM.S.INV(yield)

Tip: F.INV, T.INV en CHISQ.INV zijn links-staart inversen (kans onder de waarde); de .RT-varianten werken vanaf de rechterstaart. Let bij CI's en kritieke waarden steeds op één- vs. tweezijdig (α vs. $\alpha/2$).